دانشکده مهندسی برق و کامپیوتر

موضوع:

گزارش نهایی تمرین شماره چهار: کاربرد CLIP

عنوان گزارش:

جستجوی معنایی و تفسیر هوشمند داده‌های پزشکی

تشخیص Zero-Shot رتینوپاتی دیابتی در تصاویر شبکیه – دیتاست DeepDRiD

نام درس:

یادگیری عمیق پیشرفته

نام دانشجو:

علیرضا صادق زاده قوی فکر

شماره دانشجویی: 40317052041

استاد راهنما:

دکتر محمدجواد فدائی اسلام

آبان‌ماه 1405

Zero-Shot با برچسب ساده	Zero-Shot با جمله‌ی توصیفی	AUC بیمار/سالم (Zero-Shot)	Precision@5 جستجوی متنی	Linear Probe (مرجع نظارت‌شده)
14.3%	44.8%	0.72	0.51	63.5%

۱. هدف و خلاصه‌ی کار

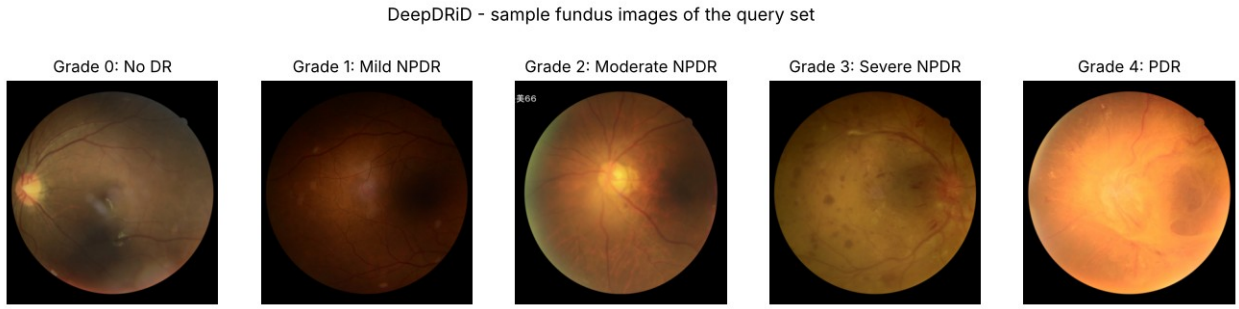
در این تمرین از مدل CLIP بدون هیچ‌گونه آموزش یا Fine-tune برای تحلیل تصاویر پزشکی استفاده شده است. دو توانایی اصلی CLIP یعنی Zero-Shot Classification و Image-Text Retrieval روی تصاویر رنگی شبکیه (Fundus) پیاده‌سازی شد تا سیستم بتواند هر تصویر را با فهرستی از جمله‌های توصیفیِ پزشکی مقایسه کند و با تابع softmax احتمال هر جمله را بدهد، و همچنین با یک توصیف متنی آزاد، تصاویر مرتبط را از میان پایگاه تصاویر پیدا کند.

نتیجه‌ی اصلی: جایگزین کردن برچسب‌های ساده با جمله‌های توصیفی پزشکی، دقت تشخیص پنج‌کلاسه را از ۱۴٫۳٪ به ۴۴٫۸٪ و AUC تفکیک بیمار از سالم را از ۰٫۵۲ به ۰٫۶۹ (و با مجموعه‌ی توصیف‌ها به ۰٫۷۲) رساند. با این حال CLIP عمومی برای درجه‌بندی دقیق بیماری کافی نیست و تحلیل آن در بخش ۷ آمده است.

۲. مجموعه داده و جدا کردن تصاویر پرس‌وجو

- **داده:** دیتاست DeepDRiD (چالش ISBI-2020): ۱۶۰۰ تصویر رنگی شبکیه با ابعاد ۱۸۲۴×۱۷۳۶ از ۴۰۰ بیمار (دو تصویر از هر چشم). هر تصویر توسط چشم‌پزشک با درجه‌ی بین‌المللی رتینوپاتی دیابتی (۰ تا ۴) و یک برچسب کیفیت تصویر برچسب خورده است.
- **پرس‌وجو (Query):** بخش validation رسمی دیتاست (۴۰۰ تصویر از ۱۰۰ بیمار) به‌عنوان تصاویر پرس‌وجو جدا شد؛ تشخیص Zero-Shot روی این تصاویر ارزیابی می‌شود.
- **گالری (Gallery):** بخش training رسمی (۱۲۰۰ تصویر از ۳۰۰ بیمار) پایگاه تصاویری است که جستجوی متن → تصویر و تصویر → تصویر در آن انجام می‌شود. تقسیم در سطح بیمار است و هیچ بیماری در هر دو بخش حضور ندارد.
- **پیش‌پردازش:** پیش‌پردازش استاندارد CLIP: تغییر اندازه به ۲۲۴ پیکسل (Bicubic)، برش مرکزی ۲۲۴×۲۲۴ و نرمال‌سازی با میانگین و انحراف معیار CLIP.

درجه	نام	علائم بالینی	گالری	پرس‌وجو
۰	No DR	شبکیه‌ی سالم	540	174
۱	Mild NPDR	فقط میکروآنوریسم	140	46
۲	Moderate NPDR	خونریزی نقطه‌ای/لکه‌ای، اگزودای سخت	234	92
۳	Severe NPDR	خونریزی گسترده، IRMA، Venous beading	214	68
۴	PDR	نورگ‌زایی، خونریزی زجاجیه	72	20
	جمع		**1200**	**400**



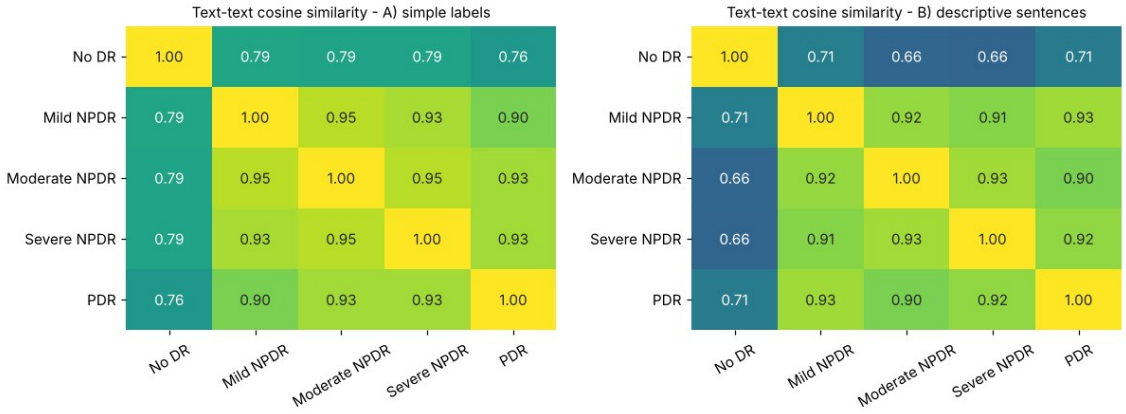
شکل ۱ – یک نمونه از هر درجه‌ی رتینوپاتی در مجموعه‌ی پرس‌وجو

۳. مدل CLIP و پرامپت‌های متنی

CLIP از یک رمزگذار تصویر (ViT-B/32) و یک رمزگذار متن (Transformer) تشکیل شده که هر دو خروجی خود را به یک فضای مشترک ۵۱۲ بعدی می‌برند و با زیان Contrastive روی صدها میلیون زوج تصویر-متن آموزش دیده‌اند. در این تمرین از پیاده‌سازی open_clip با معماری ViT-B/32 (۱۵۱ میلیون پارامتر) و وزن‌های آموزش‌دیده روی LAION-400M استفاده شد. همه‌ی بردارها L2-نرمال می‌شوند تا ضرب داخلی برابر شباهت کسینوسی باشد.

برای هر پنج درجه سه نوع برچسب متنی تعریف شد: (A) برچسب ساده به سبک a photo of ...، (B) یک جمله‌ی توصیفی پزشکی برای هر کلاس (شامل جمله‌های نمونه‌ی صورت تمرین)، و (C) مجموعه‌ای از سه جمله‌ی توصیفی برای هر کلاس که بردار کلاس میانگین نرمال‌شده‌ی آن‌ها است (Prompt Ensemble).

درجه	A) برچسب ساده	B) جمله‌ی توصیفی پزشکی
0	a photo of a healthy retina	A healthy retina with clear optic disc and blood vessels
1	a photo of mild retinopathy	A fundus image showing mild non-proliferative diabetic retinopathy with a few microaneurysms
2	a photo of moderate retinopathy	A fundus image showing moderate non-proliferative diabetic retinopathy with dot and blot hemorrhages and hard exudates
3	a photo of severe retinopathy	A fundus image showing severe non-proliferative diabetic retinopathy with extensive retinal hemorrhages, venous beading and cotton wool spots
4	a photo of proliferative retinopathy	A fundus image showing severe proliferative diabetic retinopathy with neovascularization



شکل ۲ – شباهت کسینوسی بین بردار خودِ جمله‌ها در فضای CLIP

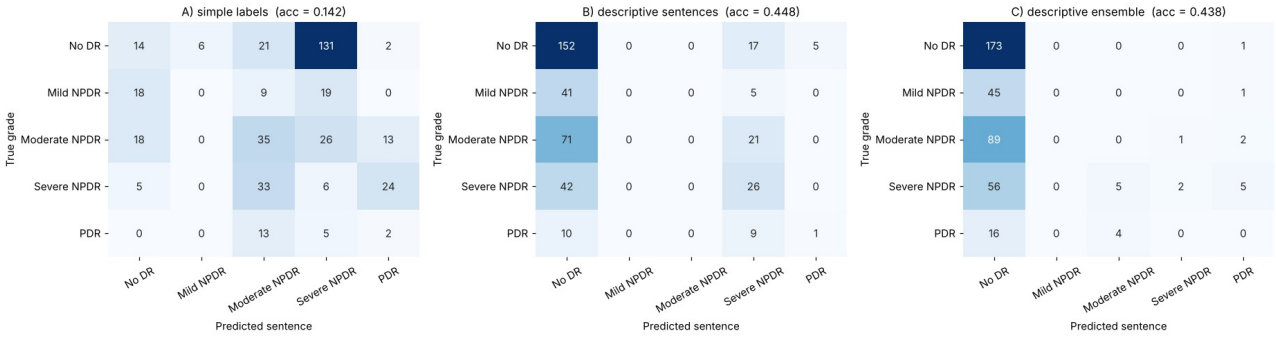
۴. تشخیص پزشکی Zero-Shot

برای هر تصویر پرس‌وجو، شباهت کسینوسی بردار تصویر با بردار هر پنج جمله محاسبه و در ضریب logit scale مدل (برابر ۱۰۰، یعنی دمای ۰٫۰۱) ضرب می‌شود؛ سپس تابع softmax روی این پنج مقدار، احتمال هر جمله (کلاس) را می‌دهد و جمله‌ی با بیشترین احتمال، تشخیص مدل است:

```
p(k | x) = softmax_k( 100 · cos( f_img(x), f_txt(t_k) ) )
```

علاوه بر دقت، از Balanced Accuracy (میانگین Recall کلاس‌ها)، Quadratic Kappa (معیار استاندارد درجه‌بندی رتینوپاتی) و AUC تفکیک بیمار از سالم (با احتمال «۱ منهای احتمال جمله‌ی سالم») استفاده شد. دقت حدس زدن کلاس اکثریت ۴۳٫۵٪ است.

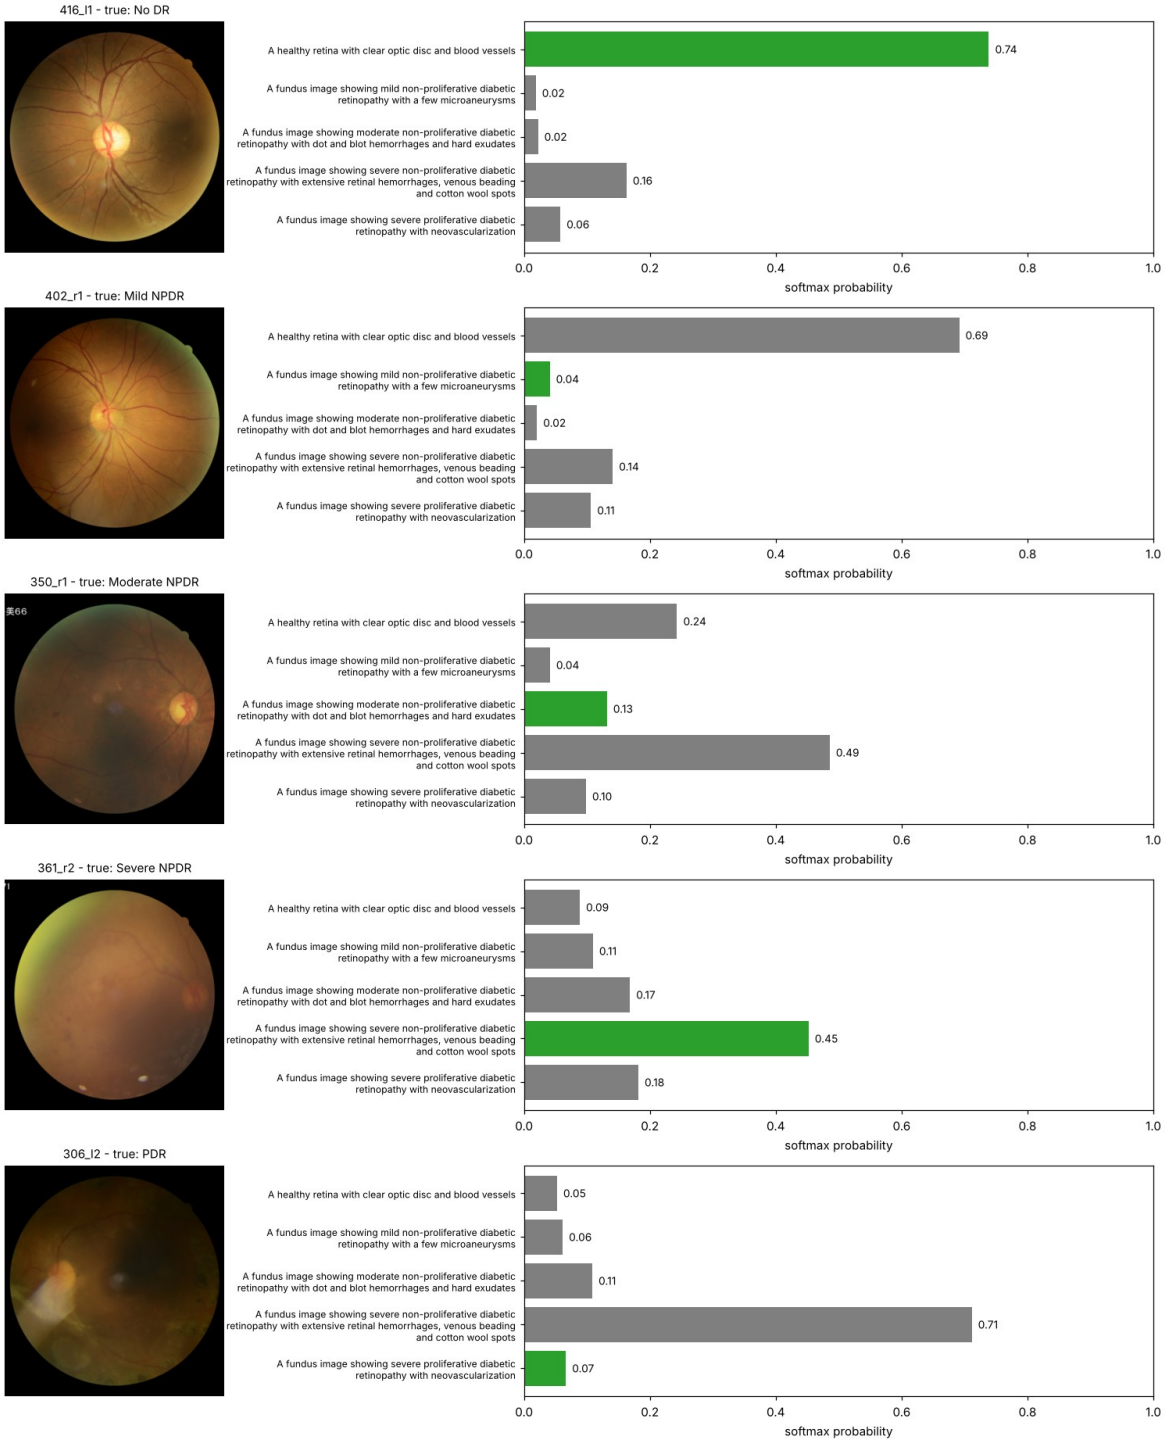
پرامپت	Accuracy	Balanced Acc.	Macro F1	Quadratic κ	AUC بیمار/سالم
A) برچسب ساده	14.3%	13.0%	0.116	0.016-	0.518
B) جمله‌ی توصیفی پزشکی	**44.8%**	**26.1%**	**0.211**	**0.226**	**0.691**
C) مجموعه‌ی توصیف‌ها	43.8%	20.5%	0.136	0.122	0.725



شکل ۳ – ماتریس درهم‌ریختگی تشخیص Zero-Shot برای سه نوع پرامپت (۴۰۰ تصویر پرس‌وجو)

گزارش کلاس‌ها برای پرامپت‌های توصیفی (B):

کلاس	Precision	Recall	F1	تعداد
No DR	0.481	0.874	0.620	174
Mild NPDR	0.000	0.000	0.000	46
Moderate NPDR	0.000	0.000	0.000	92
Severe NPDR	0.333	0.382	0.356	68
PDR	0.167	0.050	0.077	20



شکل ۴ – خروجی softmax روی پنج جمله‌ی توصیفی برای پنج تصویر پرس‌وجو (میله‌ی سبز: جمله‌ی درست)

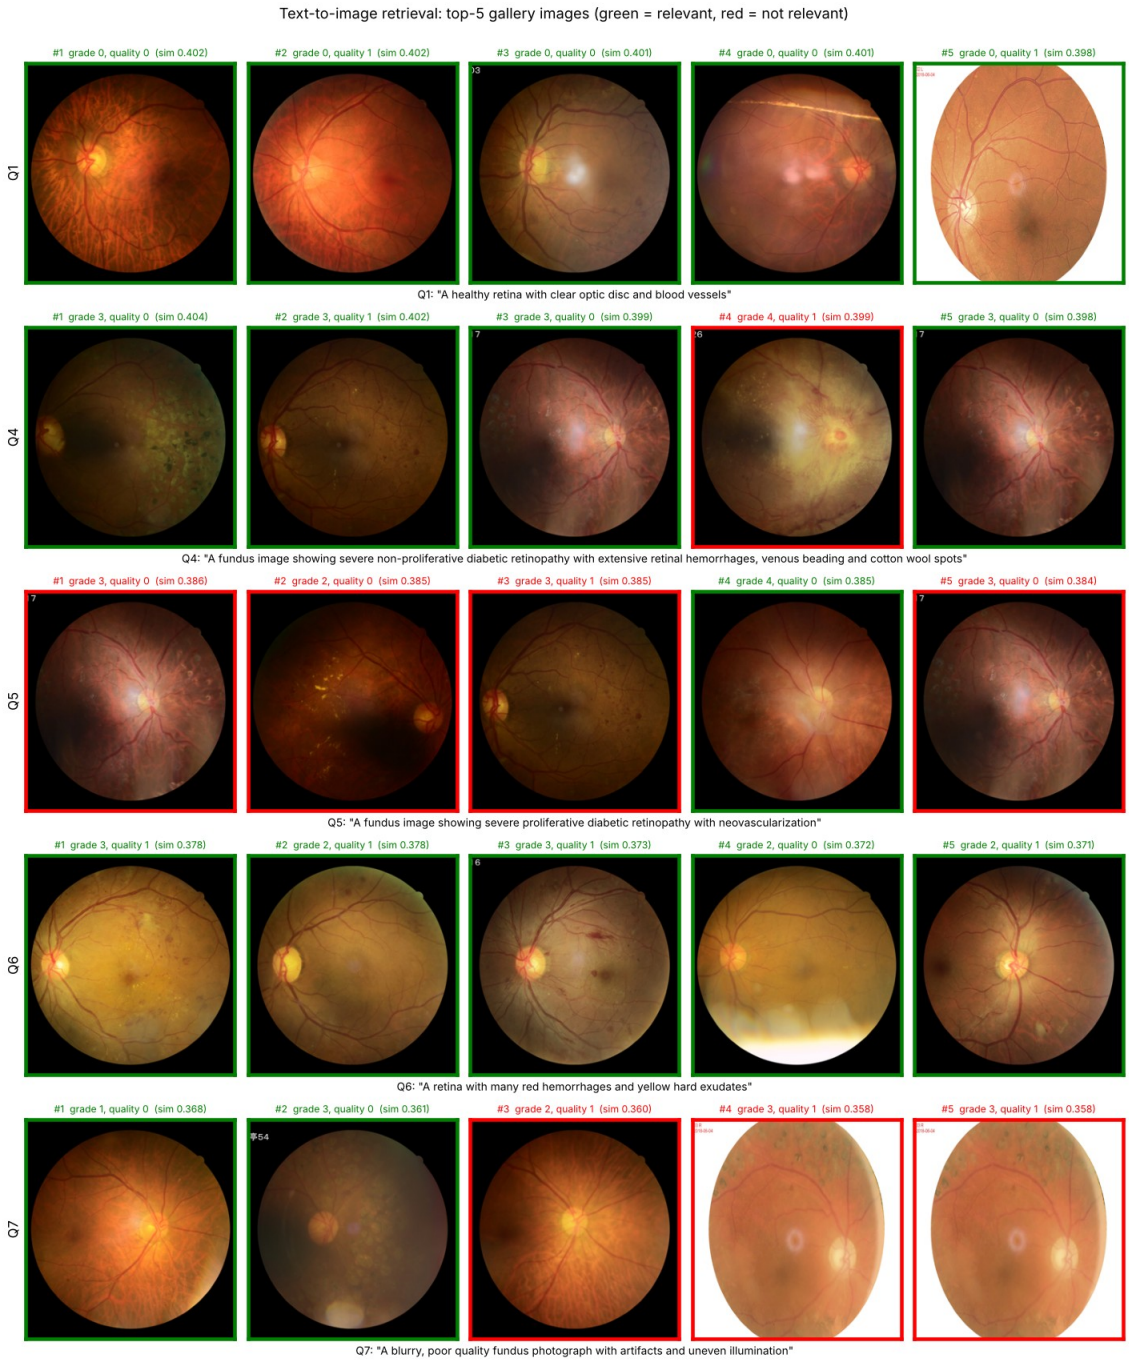
نقش دما: شباهت‌های کسینوسی یک تصویر با جمله‌های مختلف بسیار به هم نزدیک‌اند (اختلاف چند صدم). با ضریب ۱ خروجی softmax تقریباً یکنواخت (حدود ۰٫۲ برای هر کلاس) است و ضریب ۱۰۰ این اختلاف‌های کوچک را به توزیع احتمال معنادار تبدیل می‌کند؛ کلاس برنده با تغییر دما عوض نمی‌شود.

۵. جستجوی معنایی متن → تصویر

در این بخش جهت مقایسه برعکس است: یک توصیف متنی داده می‌شود و ۱۲۰۰ تصویر گالری بر اساس شباهت کسینوسی مرتب می‌شوند. علاوه بر پنج جمله‌ی توصیفی کلاس‌ها، دو پرس‌وجوی آزاد هم آزمایش شد که برچسب کلاس نیستند: توصیف یک ضایعه (تصاویر مرتبط: درجه‌ی ۲ به

بالا) و توصیف کیفیت تصـویر (تصـاویر مرتبـط: کیفیت نامناسـب بـرای تشـخیص). Base rate کسـر تصاویر مرتبط در گالری، یعنی دقت مورد انتظار جستجوی تصادفی است.

AP	P@10	P@5	Base rate	تصاویر مرتبط	پرس‌وجوی متنی	#
0.49	0.8	1.0	0.45	grade 0 (No DR)	A healthy retina with clear optic disc and blood vessels	Q1
0.12	0.3	0.0	0.12	grade 1 (Mild NPDR)	A fundus image showing mild non-proliferative diabetic retinopathy with a few microaneurysms	Q2
0.21	0.2	0.2	0.20	grade 2 (Moderate NPDR)	A fundus image showing moderate non-proliferative diabetic retinopathy with dot and blot hemorrhages and hard exudates	Q3
0.31	0.6	0.8	0.18	grade 3 (Severe NPDR)	A fundus image showing severe non-proliferative diabetic retinopathy with extensive retinal hemorrhages, venous beading and cotton wool spots	Q4
0.07	0.2	0.2	0.06	grade 4 (PDR)	A fundus image showing severe proliferative diabetic retinopathy with neovascularization	Q5
0.45	0.9	1.0	0.43	grade >= 2 (lesions visible)	A retina with many red hemorrhages and yellow hard exudates	Q6
0.50	0.4	0.4	0.52	poor image quality	A blurry, poor quality fundus photograph with artifacts and uneven illumination	Q7
0.31	**0.49**	**0.51**	**0.28**		**mean**	

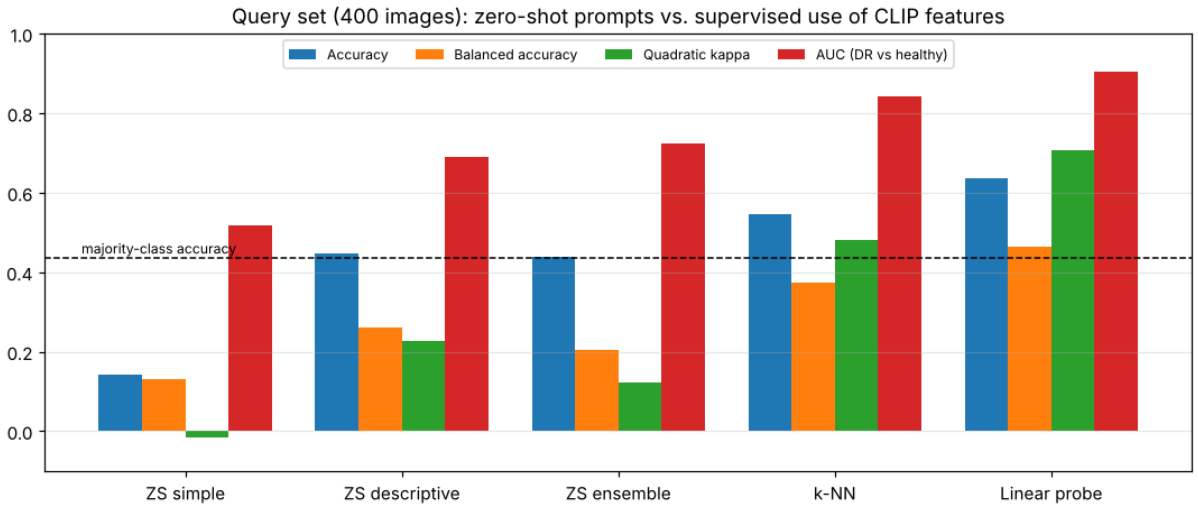


شکل ۵ – پنج نتیجه‌ی اول جستجوی متن → تصویر (قاب سبز: مرتبط، قاب قرمز: نامرتبط)

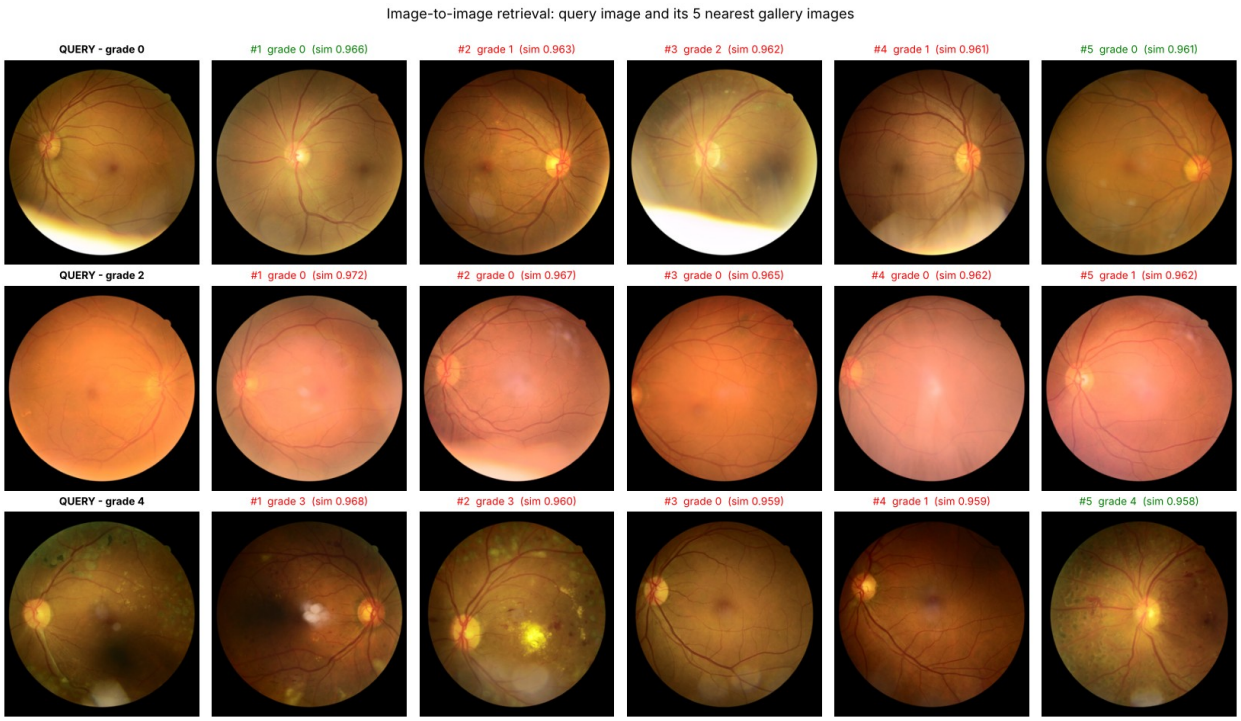
۶. جستجوی تصویر → تصویر و مقایسه با روش‌های نظارت‌شده

برای تشخیص اینکه محدودیت نتایج از رمزگذار تصویر است یا از تطابق متن و تصویر، همان بردارهای تصویری CLIP به دو روش دیگر استفاده شدند: k-NN (برای هر تصویر پرس‌وجو، ۱۰ تصویر شبیه‌تر گالری و رأی اکثریت درجه‌ی آن‌ها) و Linear Probe (رگرسیون لجستیک روی بردارهای گالری). این دو روش از برچسب‌های گالری استفاده می‌کنند و دیگر Zero-Shot نیستند.

روش	Accuracy	Balanced Acc.	Quadratic κ	AUC بیمار/سالم
Zero-Shot – برچسب ساده	14.3%	13.0%	0.016-	0.518
Zero-Shot – جمله‌ی توصیفی	44.8%	26.1%	0.226	0.691
Zero-Shot – مجموعه‌ی توصیف‌ها	43.8%	20.5%	0.122	0.725
k-NN تصویر → تصویر (k=10)	54.5%	37.5%	0.482	0.842
Linear Probe روی ویژگی‌های CLIP	63.5%	46.5%	0.706	0.905



شکل ۶ – مقایسه‌ی روش‌ها روی ۴۰۰ تصویر پرس‌وجو



شکل ۷ – جستجوی تصویر → تصویر: تصویر پرس‌وجو و پنج همسایه‌ی نزدیک آن در گالری

۷. تحلیل نتایج و جمع‌بندی

- **توصیف پزشکی مؤثر است:** با برچسب‌های ساده، CLIP بدتر از حدس کلاس اکثریت عمل می‌کند (۱۴٫۳٪) و ۱۳۱ تصویر از ۱۷۴ تصویر سالم را severe retinopathy می‌نامد. جمله‌های توصیفی با واژگان بالینی (exudate، hemorrhage، optic disc و ...) دقت را به ۴۴٫۸٪ و κ را از منفی ۰٫۰۲ به ۰٫۲۳ می‌رسانند.
- **Zero-Shot برای درجه‌بندی ریز کافی نیست:** مدل تقریباً فقط بین جمله‌ی «سالم» و «Severe NPDR» انتخاب می‌کند و درجه‌های ۱ و ۲ را هرگز پیش‌بینی نمی‌کند (Recall صفر). تفاوت این درجه‌ها ضایعات بسیار ریز مانند میکروآنوریسم است که در ورودی ۲۲۴×۲۲۴ تقریباً دیده نمی‌شوند و در داده‌ی آموزشی عمومی CLIP هم زوج تصویر-متن کافی برای آن‌ها وجود نداشته است. دقت کلی ۴۴٫۸٪ هم فقط کمی بالاتر از حدس کلاس اکثریت (۴۳٫۵٪) است.

- **Prompt Ensemble:** میانگین‌گیری از چند توصیف، تفکیک بیمار از سالم را بهتر کرد (AUC از ۰٫۶۹ به ۰٫۷۲) ولی پیش‌بینی‌ها را بیشتر به سمت کلاس سالم برد و Balanced Accuracy را کاهش داد؛ یعنی رتبه‌بندی بهتر شده اما مرز تصمیم softmax نامتعادل است.
- **جستجوی معنایی بهتر از طبقه‌بندی عمل می‌کند:** میانگین Precision@5 برابر ۰٫۵۱ در مقابل Base rate برابر ۰٫۲۸ است. برای «شبکیه‌ی سالم» (P@5 = 1.0)، «Severe NPDR» (0.8) و «خونریزی و اگزودا» (1.0) نتایج اول تقریباً همه مرتبط‌اند؛ اما برای PDR، Mild NPDR و توصیف کیفیت تصویر، نتایج در حد تصادفی یا پایین‌تر است.
- **گلوگاه، سمت متن است:** با همان بردارهای تصویر، k-NN به دقت ۵۴٫۵٪ و Linear Probe به دقت ۶۳٫۵٪ (κ = 0.71 و AUC = 0.91) می‌رسد. پس ویژگی‌های تصویری CLIP اطلاعات بیماری را دارند و محدودیت اصلی، هم‌ترازی متن پزشکی با تصویر است.
- **پیشنهاد برای بهبود:** استفاده از مدل‌های CLIP تخصصی پزشکی (مانند BiomedCLIP یا FLAIR برای شبکیه)، ورودی با تفکیک‌پذیری بالاتر یا برش ناحیه‌ای تصویر، و Fine-tune یا Prompt Learning با تعداد کمی نمونه‌ی برچسب‌دار.

این سیستم یک تمرین آموزشی است و برای تشخیص بالینی قابل استفاده نیست.

۸. فایل‌ها و نحوه‌ی اجرا

- **نوت‌بوک:** ADL_HW4_CLIP_Medical.ipynb – نوت‌بوک اصلی که همه‌ی سلول‌های آن اجرا شده است (حدود ۳ دقیقه روی CPU چهار هسته‌ای).
- **خروجی‌ها:** پوشه‌ی outputs شامل نمودارها و جدول‌های CSV این گزارش.
- **اجرا:** پس از نصب requirements.txt کافی است همه‌ی سلول‌ها اجرا شوند؛ دیتاست DeepDRiD و وزن‌های CLIP در صورت نبودن، خودکار دانلود می‌شوند.